Implementierung von Counterfactual Regret Minimization in zunehmend komplexen Pokervarianten

vorgelegt von

Friedemann Doll

EDV.Nr.:924315

dem Fachbereich VI – Informatik und Medien
der Berliner Hochschule für Technik Berlin
vorgelegte Bachelorarbeit
zur Erlangung des akademischen Grades

Bachelor of Engineering (B.Eng.)

im Studiengang

Technische Informatik

Tag der Abgabe 11. Januar 2026

Gutachter
Prof. Dr.-Ing. Stefan Edlich Berliner Hochschule für Technik

BHT Berliner Hochschule für Technik

Studiere Zukunft

Inhaltsverzeichnis

1 Einleitung **7**

1.1 Motivation und Relevanz 7

1.2 Zielsetzung und Fragestellungen 8

1.3 Aufbau der Arbeit 9

2 Theoretische Grundlagen **11**

2.1 Grundlagen der Spieltheorie 11

2.1.1 Definition und Konzepte 11

2.1.2 Extensive Games with Imperfect Information 13

2.2 Counter Factual Regret Minimization 15

2.2.1 Definitionen 15

2.2.2 Regret Minimization 16

2.2.3 Counterfactual Regret 17

2.2.4 Regret Matching 18

2.2.5 CFR Algorithmus 18

2.3 Monte Carlo CFR 19

2.3.1 Allgemeine Definition 19

2.3.2 Chance Sampling CFR 20

2.3.3 External Sampling MCCFR 20

2.3.4 Outcome Sampling MCCFR 20

2.3.5 Theoretische Eigenschaften 21

2.4 CFR+ 23

2.4.1 Unterschiede zu Vanilla CFR 23

2.4.2 Regret Matching+ 24

2.4.3 Tracking Regret 25

2.4.4 Linear Weighted Average 25
2.5 Hold'em Games 26
2.5.1 Kuhn Poker 27
2.5.2 Leduc Hold'em 27
2.5.3 Zwölf Karten Variante 28
2.5.4 Rhode Island Hold'em 28
2.5.5 Limit Texas Hold'em 28

3 Analyse 31
3.1 Spielvarianten 31
3.2 CFR Solver 32
3.3 Evaluationsmethoden 32

4 Design und Architektur 33
4.1 Game Environment 33
4.2 CFR Solver 35
4.2.1 CFR Training Ablauf 36
4.2.2 Traverse Game Tree 37
4.2.3 Strategy Agent und Logger 37

5 Implementierung 39
5.1 Game Environment 39
5.2 CFR Solver 39
5.3 Evaluationsmethoden 39

6 Evaluation 41
6.1 Ergebnisse 41
6.2 Vergleich der Algorithmen 41
6.3 Vergleich mit Literaturwerten und anderen Modellen 41

7 Fazit 43
7.1 Zusammenfassung 43
7.2 Lessons Learned 43
7.3 Future Work 43

Literaturverzeichnis **44**

Kapitel 1

Einleitung

1.1 Motivation und Relevanz

Es gibt unzählige Situationen, in welchen Entscheidungen getroffen werden, ohne dass der Entscheidungsträger vollständig über alle relevanten Umstände informiert ist. In einer solchen Situation treffen Menschen bewusst oder unterbewusst Annahmen über die unbekannten Umstände, um weiterhin handlungsfähig zu bleiben.
Die Spieltheorie beschäftigt sich unter anderem mit der Analyse solcher Entscheidungsprozesse in realen Situationen sowie in Spielen verschiedener Art. 5Das wohl populärste Beispiel hierfür ist Poker, insbesondere Hold'em Varianten, wie No-Limit Texas-Hold'em.

Ich habe im letzten Jahr ein ausgeprägtes Interesse für das Spiel No-Limit Texas Hold'em entwickelt. Wenn man sich mit Strategien für Poker auseinandersetzt, stößt man schnell auf ein Konzept, welches Game Theory Optimized, kurz GTO, genannt wird. Dieses Konzept hat innerhalb der letzten Jahre immer mehr an Relevanz und Aufmerksamkeit gewonnen und ist heutzutage kaum noch aus der Pokerwelt wegzudenken. Eine GTO-Strategie ist im Grunde eine spieltheoretisch optimale Lösung, welche durch den Einsatz von Algorithmen approximiert wird. Diese Strategien sind für Spiele mit einem enorm großen Zustandsraum, wie No Limit Hold'em, extrem komplex und können von einem Menschen niemals vollständig auswendig gelernt und exekutiert werden. Pokerprofis sind allerdings in der Lage, diese Strategien in abstrahierter Form zu adaptieren, indem sie grundlegende strategische Prinzipien und Verhaltensmuster erkennen und anschließend auf ihre Spielsituationen anwenden. Die intensive Beschäftigung mit GTO-Strategien in meiner Freizeit weckte mein Interesse an den algorithmischen Grundlagen, die zur Berechnung solcher Strategien verwendet werden.

Ein zentraler Algorithmus, welcher in diesem Bereich verwendet wird, ist Counterfactual Regret Minimization, kurz CFR. Seit seiner Einführung durch Zinkevich et al. im Jahr 2007 [Zinkevich et al., 2007] hat sich CFR als einer der erfolgreichsten Ansätze etabliert und bildet die Grundlage für mehrere bahnbrechende Poker-KIs.
Bowling et al. zeigten mit Cepheus, dass CFR in der Lage ist, Heads-Up Limit Texas Hold'em zu lösen [Bowling et al., 2015]. Brown und Sandholm demonstrierten mit Libratus, dass CFR-basierte Ansätze in der Lage sind, professionelle Spieler in Heads-Up No-Limit Texas Hold'em zu schlagen [Brown and Sandholm, 2017].

Mit Pluribus wurde gezeigt, dass diese Methoden auch in Multiplayer-Szenarien erfolgreich sind [Brown and Sandholm, 2019].

1.2 Zielsetzung und Fragestellungen

Im Rahmen dieser Arbeit wird Counterfactual Regret Minimization implementiert und auf verschiedenen Pokervarianten unterschiedlicher Komplexität angewendet. Dabei soll untersucht werden, wie sich die Leistungsfähigkeit des Algorithmus mit steigender Spielkomplexität in Bezug auf Parameter wie Laufzeit und Speicherbedarf verhält. Außerdem wird ermittelt, ab welchem Komplexitätsgrad algorithmische und implementierungsspezifische Optimierungsverfahren notwendig werden.

Ursprünglich waren im Exposé drei Pokervarianten geplant: Kuhn Poker als einfachste Variante, Leduc Hold'em als etabliertes Forschungsspiel und eine selbst entwickelte Pokervariante mit zwölf Karten als Zwischenstufe der Komplexität. Zusätzlich sollten alternative Versionen wie CFR+ und Monte Carlo CFR implementiert werden, um deren Auswirkungen auf verschiedene Parameter des Lernprozesses zu untersuchen. Zur Evaluation der Qualität trainierter Strategien wird deren Ausnutzbarkeit mittels des Best Response Agents ermittelt.

Zur Beantwortung der genannten Ziele werden folgende Forschungsfragen untersucht:

1. **Komplexitätsverhalten:** Wie verhält sich CFR bei zunehmender Spielkomplexität? Welche Faktoren wie Anzahl der Karten, Betting-Runden oder Bet-Limits beeinflussen die Konvergenzgeschwindigkeit und den Ressourcenbedarf am stärksten?

2. **Optimierungsverfahren:** Ab welchem Komplexitätsgrad werden Optimierungsverfahren wie CFR+ oder MCCFR zwingend erforderlich? Welche Verbesserungen können durch diese Varianten erzielt werden?

3. **Skalierbarkeit:** Welche Grenzen existieren für die direkte Anwendung von CFR ohne weitere Abstraktionstechniken? Bis zu welcher Komplexität können Pokervarianten erfolgreich gelöst werden?

4. **Algorithmenvergleich:** Wie unterscheiden sich die verschiedenen CFR-Varianten hinsichtlich Konvergenzgeschwindigkeit, Speicherverbrauch und finaler Strategiequalität?

1.3 Aufbau der Arbeit

Die Arbeit gliedert sich in sieben Kapitel, die den Weg von den theoretischen Grundlagen bis zur Evaluation der trainierten Strategien beschreiben.

Kapitel 2 stellt die theoretischen Grundlagen vor. Es werden spieltheoretische Konzepte eingeführt, insbesondere Extensive Games with Imperfect Information, Information Sets und Nash-Gleichgewichte. Anschließend wird Counterfactual Regret Minimization detailliert erläutert, gefolgt von den Optimierungsverfahren MCCFR und CFR+. Anschließend wird die Theorie des Accelerated Best Response Agents erläutert, welcher zur Evaluation verwendet wird.

Kapitel 3 analysiert die Anforderungen an die Implementierung. Es werden die verschiedenen Pokervarianten vorgestellt, die zu implementierenden CFR-Varianten analysiert und die Evaluationsmethoden definiert.

Kapitel 4 beschreibt die Systemarchitektur anhand von UML-Diagrammen, wobei sowohl die Struktur der Spielumgebung als auch die des CFR-Solvers erläutert werden.

Kapitel 5 dokumentiert die konkrete Implementierung der Spielumgebung, des CFR-Solvers sowie der Evaluationsmethoden.

Kapitel 6 präsentiert die Ergebnisse der Evaluation. Für jede Pokervariante werden die Ergebnisse der verschiedenen Algorithmen dargestellt und mit Literaturwerten verglichen.

Kapitel 7 fasst die Erkenntnisse zusammen, diskutiert Limitationen und gibt einen Ausblick auf mögliche Erweiterungen.

Kapitel 2

Theoretische Grundlagen

2.1 Grundlagen der Spieltheorie

In diesem Kapitel gebe ich einen kurzen Überblick darüber, was Spieltheorie ist und wo sie angewendet wird. Dabei definiere ich, was ein Spiel ist und was eine Lösung ist. Anschließend umreiße ich die wichtigsten Typen von Spielen und gehe dann genauer auf den Typ extensiver Spiele mit imperfekter Information ein.

2.1.1 Definition und Konzepte

Die Spieltheorie beschäftigt sich mit der Analyse strategischer Interaktionen zwischen Entscheidungsträgern und bietet hierfür eine Vielzahl analytischer Methoden. Diese basieren auf zwei zentralen Annahmen [Osborne and Rubinstein, 1994, Kap. 1.1].

Die erste Annahme ist, dass Entscheidungsträger rational handeln. Ein rationaler Entscheidungsträger kennt seine Handlungsmöglichkeiten, kann Erwartungen über unbekannte Situationen bilden und hat klare Vorstellungen darüber, welche Ergebnisse er bevorzugt. Er wählt seine Aktion bewusst nach einem Prozess der Optimierung. Liegt keine Unsicherheit vor, wählt er die Aktion, die zu den für ihn besten Konsequenzen führt.
Diese Präferenzen lassen sich durch eine Nutzenfunktion beschreiben, die jedem möglichen Ergebnis einen Wert zuordnet. Die beste Aktion ist die, welche den höchsten Nutzen erzielt. Sind die Konsequenzen von Aktionen unsicher, maximiert ein rationaler Entscheidungsträger den erwarteten Nutzen. Hierfür muss er in der Lage sein, Wahrscheinlichkeiten für unsichere Ereignisse abzuschätzen [Osborne and Rubinstein, 1994, Kap. 1.4].

Die zweite Annahme ist, dass Entscheidungsträger ihr Wissen oder ihre Erwartungen über das Verhalten anderer Spieler bei ihrer Entscheidungsfindung nutzen. Dies nennt man auch strategisches Handeln. Spieltheoretisches Denken berücksichtigt, dass jeder Entscheidungsträger vor seiner Entscheidung versucht, Informationen über das Verhalten der anderen Spieler zu erhalten. Im Gegensatz dazu nimmt die Theorie des Wettbewerbsgleichgewichts an, dass jeder Akteur sich nur für Umgebungsparameter wie Preise interessiert, auch wenn diese durch die Aktionen aller Akteure bestimmt werden [Osborne and Rubinstein, 1994, Kap. 1.3].

Ein anschauliches Beispiel hierfür ist das Gefangenendilemma. Zwei Verdächtige werden getrennt verhört und müssen jeweils entscheiden, ob sie schweigen oder den anderen belasten. Schweigen beide, erhalten beide 2 Jahre Haft; gestehen beide, erhalten beide 5 Jahre Haft; gesteht jedoch nur einer, wird dieser freigelassen, während der Schweigende 10 Jahre Haft erhält. Die optimale Entscheidung hängt davon ab, was der andere Gefangene vermutlich tut. Strategisches Handeln bedeutet, solche Erwartungen über das Verhalten anderer Spieler in die Entscheidungsfindung einzubeziehen [Osborne and Rubinstein, 1994, Kap. 1.1].

Spieltheoretische Modelle befinden sich auf einer hohen Abstraktionsebene und können daher verwendet werden, um ein breites Spektrum an Phänomenen zu betrachten. Zur formalen Darstellung dieser Modelle werden mathematische Definitionen genutzt. Die behandelten Konzepte sind jedoch nicht grundlegend mathematisch und können auch ohne mathematische Notation beschrieben werden.
Die Spieltheorie findet Anwendung in unzähligen Bereichen. Zu den klassischen Anwendungsgebieten zählen die Analyse wirtschaftlicher und politischer Wettbewerbssituationen. Darüber hinaus wird sie auch in der Evolutionsbiologie, der Soziologie und anderen Disziplinen genutzt, um strategische Interaktionen zu modellieren
[Osborne and Rubinstein, 1994, Kap. 1.1].

Ein Spiel beschreibt eine strategische Interaktion zwischen Spielern mit festgelegten Rahmenbedingungen. Es definiert, welche Aktionen den Spielern zur Verfügung stehen und welche Ergebnisse in ihrem Interesse sind. Das Spiel legt damit die Struktur und die Regeln der Interaktion fest, bestimmt aber nicht, wie sich die Spieler tatsächlich verhalten werden.
Die Frage, welche Aktionen die Spieler tatsächlich ausführen, wird nicht durch das Spiel selbst beantwortet, sondern durch die Lösung des Spiels. Eine Lösung ist ein Konzept, das systematisch beschreibt, welche Ergebnisse in einer Klasse von Spielen unter bestimmten Verhaltensannahmen zu erwarten sind. Sie liefert damit eine Vorhersage über das tatsächliche Verhalten der Spieler unter den getroffenen Annahmen über Rationalität und strategisches Denken [Osborne and Rubinstein, 1994, Kap. 1.2].

Spiele können anhand verschiedener Kriterien systematisch kategorisiert werden. Grundlegend für alle spieltheoretischen Modelle ist das Konzept des Spielers. Ein Spieler kann dabei sowohl eine einzelne Person als auch eine Gruppe von Personen darstellen, die gemeinsam eine Entscheidung treffen.

Die erste grundlegende Unterscheidung betrifft kooperative und nicht kooperative Spiele. Nicht kooperative Spiele modellieren die Aktionen einzelner Spieler. Kooperative Spiele hingegen konzentrieren sich darauf, was Gruppen von Spielern gemeinsam erreichen können. Dabei wird nicht betrachtet, wie diese Gruppen intern funktionieren.

Eine weitere wichtige Kategorisierung betrifft die Darstellungsform des Spiels. Hierbei werden strategische Spiele, auch als Spiele in Normalform bezeichnet, von extensiven Spielen unterschieden. Bei strategischen Spielen wählen die Spieler ihre Strategie zu Beginn des Spiels und passen diese während des Spielverlaufs nicht mehr an. Die Entscheidungen werden zudem simultan getroffen, sodass keine Informationen über die Aktionen der Gegenspieler verfügbar sind. Extensive Spiele hingegen spezifizieren die möglichen Reihenfolgen von Ereignissen und erlauben es jedem Spieler, seinen Aktionsplan nicht nur zu Beginn, sondern auch bei jeder weiteren Entscheidung zu überdenken.

Die letzte hier zu nennende Unterscheidung betrifft den Informationsstand der Spieler. Bei Spielen mit perfekter Information sind alle Teilnehmer vollständig über die Züge der anderen Spieler informiert. Bei Spielen mit imperfekter Information hingegen können die Spieler unvollständig über die Aktionen der anderen oder über Ausgänge von Zufallsereignissen informiert sein [Osborne and Rubinstein, 1994, Kap. 1.2].

2.1.2 Extensive Games with Imperfect Information

Nachdem die grundlegenden Konzepte der Spieltheorie eingeführt wurden, widmet sich dieses Kapitel den extensiven Spielen mit imperfekter Information. Diese Spielklasse ist für die vorliegende Arbeit von zentraler Bedeutung, da die meisten Pokerspiele, insbesondere Hold'em-Varianten, zu den extensiven Spielen mit imperfekter Information gehören.

Definition

Ein extensives Spiel mit imperfekter Information modelliert eine sequenzielle Interaktion zwischen Spielern, bei der nicht alle Spieler stets vollständig über alle vergangenen Aktionen informiert sind. Dabei werden die möglichen Spielverläufe als Historien erfasst, wobei eine Historie eine Abfolge von Aktionen darstellt. Zu jedem Zeitpunkt ist entweder ein Spieler oder der Zufall am Zug. Um die imperfekte Information darzustellen, werden Informationssets verwendet. Diese fassen Zustände zusammen, die ein Spieler nicht voneinander unterscheiden kann. Dies kann sowohl vergangene Aktionen anderer Spieler als auch Ausgänge von Zufallsereignissen betreffen.

Ein extensives Spiel mit imperfekter Information lässt sich formal durch folgende Komponenten definieren:

- Eine Menge von Historien H. Eine Historie ist eine endliche oder unendliche Sequenz von Aktionen, getätigt von Spielern oder dem Zufall.
  Die Menge H erfüllt folgende Eigenschaften:
  - Die leere Sequenz $\emptyset$ ist ein Element von H.
  - Ist $(a^k)_{k=1,\ldots,K} \in H$ (wobei K unendlich sein kann) und $L < K$, dann gilt $(a^k)_{k=1,\ldots,L} \in H$. Das bedeutet, wenn eine Sequenz ein Teil von H ist, dann ist auch jeder Präfix dieser Sequenz ein Teil von H.
  - Wenn für eine unendliche Folge $(a^k)_{k=1}^{\infty}$ die Bedingung $(a^k)_{k=1,\ldots,L} \in H$ für jede positive ganze Zahl L erfüllt ist, dann gilt $(a^k)_{k=1}^{\infty} \in H$.
- Eine Historie $(a^k)_{k=1,\ldots,K} \in H$ ist terminal, wenn sie unendlich ist oder wenn kein a^{K+1} existiert, so dass $(a^k)_{k=1,\ldots,K+1} \in H$ gilt. Man bezeichnet die Menge aller terminalen Historien mit Z.
  Die Menge der Aktionen, die nach einer nicht-terminalen Historie h verfügbar sind, wird mit $A(h) = \{a : (h, a) \in H\}$ bezeichnet.
- Die Funktion P ordnet jeder nicht-terminalen Historie $h \in H \setminus Z$ einen Spieler aus N oder c zu. $P(h)$ bezeichnet den Spieler, der nach h am Zug ist. In dem Fall, das $P(h) = c$ ist, bestimmt der Zufall die nächste Aktion.

- Die Funktion f_c ordnet jeder Historie h mit $P(h) = c$ eine Zufallsverteilung $f_c(\cdot \mid h)$ auf $A(h)$ zu. $f_c(a \mid h)$ ist die Wahrscheinlichkeit, dass nach h die Aktion a folgt. Diese Verteilungen sind unabhängig voneinander.

- Für jeden Spieler $i \in N$ werden die Historien h, bei denen $P(h) = i$ gilt, in Gruppen eingeteilt. Diese Menge heißt Informationspartition $\mathcal{I}i$ von Spieler i. Eine solche Gruppe $I_i \in \mathcal{I}_i$ heißt Informationsset von Spieler i. Historien h und h', die zum selben Informationsset I_i gehören, sind für Spieler i nicht unterscheidbar.

  Wesentlich ist dabei, dass alle Historien in einem Informationsset I_i die gleichen verfügbaren Aktionen haben, also $A(h) = A(h')$ für alle $h, h' \in I_i$. Für ein Informationsset I_i schreiben wir $A(I_i)$ für die verfügbaren Aktionen und $P(I_i)$ für den Spieler, der am Zug ist.

- Für jeden Spieler $i \in N$ gibt es eine Präferenzrelation $\succeq_i$ über Lotterien auf Z. Eine Lotterie ist eine Wahrscheinlichkeitsverteilung über Endzustände. Es existiert eine Nutzenfunktion $u_i : Z \to \mathbb{R}$, so dass für zwei Lotterien L_1, L_2 gilt: $L_1 \succeq_i L_2 \iff \mathbb{E}[u_i \mid L_1] \geq \mathbb{E}[u_i \mid L_2]$

Formale Definition entspricht [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.1, Def. 200.1].

Strategien

In extensiven Spielen mit imperfekter Information gibt es verschiedene Möglichkeiten, wie die Strategien von Spielern definiert sein können.
Eine reine Strategie von Spieler $i \in N$ ordnet jedem Informationsset $I \in \mathcal{I}_i$ genau eine zulässige Aktion $\sigma_i(I) \in A(I)$ zu. Sie legt somit einen vollständigen Handlungsplan für alle Informationslagen von i fest.
Eine gemischte Strategie α_i ist eine Wahrscheinlichkeitsverteilung über der Menge der reinen Strategien von i.
Eine behavioral Strategie β_i hingegen ist eine Sammlung unabhängiger Wahrscheinlichkeitsverteilungen $(\beta_i(I))_{I \in \mathcal{I}_i}$, wobei $\beta_i(I)$ eine Wahrscheinlichkeitsverteilung über die Aktionen $A(I)$ am Informationsset I ist [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.4, Def. 212.1].
Der Unterschied liegt darin, dass bei einer gemischten Strategie vor Spielbeginn zufällig eine komplette reine Strategie ausgewählt wird, die dann während des gesamten Spiels deterministisch befolgt wird. Im Gegensatz dazu wird bei einer behavioral Strategie in jedem Informationsset unabhängig eine Wahrscheinlichkeitsverteilung über die verfügbaren Aktionen verwendet, sodass die zufällige Auswahl der Aktionen während des Spiels erfolgt [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.4].
Ein extensives Spiel hat perfect recall, wenn jeder Spieler zu jedem Zeitpunkt alles erinnert, was er in der Vergangenheit wusste und welche Aktionen er selbst getroffen hat [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.1].
Unter der Annahme von perfect recall erzeugen beide Repräsentationen outcome-äquivalente Wahrscheinlichkeitsverteilungen über die terminalen Historien [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.4, Prop. 214.1].

Ein Profil von behavioral Strategien $\beta = (\beta_i)_{i \in N}$ zusammen mit den Zufallszügen f_c bestimmt eine Wahrscheinlichkeitsverteilung über die terminalen Historien Z. Daraus lässt sich für jede Auszahlungsfunktion u_i der Erwartungswert $\mathbb{E}[u_i \mid \beta, f_c]$ berechnen.

Ein Nash-Gleichgewicht beschreibt ein Strategienprofil, bei dem kein Spieler durch eine einseitige Änderung seiner Strategie seinen erwarteten Nutzen erhöhen kann. Formal ist ein Strategienprofil σ^* ein Nash-Gleichgewicht in gemischten Strategien, wenn für jeden Spieler $i \in N$ und für jede gemischte Strategie σ_i von Spieler i die Bedingung

$$O(\sigma^*_{-i}, \sigma^*_i) \succeq_i O(\sigma^*_{-i}, \sigma_i) \tag{2.1}$$

erfüllt ist, wobei $O(\sigma)$ die durch das Strategienprofil σ entstehende Lotterie über Endzuständen bezeichnet [Osborne and Rubinstein, 1994, Ch. 11, Sec. 11.5].

2.2 Counter Factual Regret Minimization

In diesem Kapitel behandle ich die Theorie des Herzstücks dieser Arbeit, des Counterfactual Regret Minimization Algorithmus. Die fachliche Grundlage bildet das Paper „Regret Minimization in Games with Incomplete Information “ [Zinkevich et al., 2007], in dem der Counterfactual Regret Minimization Algorithmus erstmals präsentiert wurde. Hierbei beginne ich mit einer Erklärung des Konzepts Regret. Anschließend erkläre ich, wann ein Algorithmus als regret-minimierend gilt. Dann erläutere ich das von Zinkevich eingeführte Konzept des Counterfactual Regrets sowie Regret Matching. Am Ende fügen sich die einzelnen Komponenten zu einem Algorithmus zusammen.

2.2.1 Definitionen

Dieser Abschnitt führt die grundlegenden Definitionen und Konzepte ein, die für das Verständnis von Counterfactual Regret Minimization notwendig sind.

Wahrscheinlichkeiten und Werte

Für ein Strategieprofil σ definieren wir folgende Wahrscheinlichkeiten und Werte:

Die Wahrscheinlichkeit, dass eine History h auftritt, wenn alle Spieler gemäß σ handeln, bezeichnen wir mit $\pi^\sigma(h)$. Diese Wahrscheinlichkeit kann in ein Produkt zerlegt werden:

$$\pi^\sigma(h) = \prod_{i \in N \cup \{c\}} \pi^\sigma_i(h), \tag{2.2}$$

wobei $\pi^\sigma_i(h)$ die Wahrscheinlichkeit bezeichnet, dass Spieler i in all seinen Entscheidungsknoten auf dem Pfad zu h gemäß σ die Aktionen gewählt hat, die zu h führen. Das Produkt der Wahrscheinlichkeiten aller anderen Spieler (inklusive Chance) bezeichnen wir mit $\pi^\sigma_{-i}(h)$.

Für ein Informationsset I definieren wir die Erreichbarkeitswahrscheinlichkeit als

$$\pi^\sigma(I) = \sum_{h \in I} \pi^\sigma(h). \tag{2.3}$$

Analog definieren wir $\pi^\sigma_i(I)$ und $\pi^\sigma_{-i}(I)$ als die Wahrscheinlichkeiten, dass Spieler i beziehungsweise die anderen Spieler das Informationsset I erreichen.

Der erwartete Payoff für Spieler i unter Strategieprofil σ, auch *Overall Value* genannt, berechnet sich als

$$u_i(\sigma) = \sum_{h \in Z} u_i(h)\pi^{\sigma}(h), \tag{2.4}$$

Nash Gleichgewicht

Ein Nash Gleichgewicht für ein Zweispieler Nullsummenspiel ist ein Strategieprofil $\sigma = (\sigma_1, \sigma_2)$, welches folgende Ungleichungen erfüllt:

$$u_1(\sigma) \geq \max_{\sigma_1' \in \Sigma_1} u_1(\sigma_1', \sigma_2), \qquad u_2(\sigma) \geq \max_{\sigma_2' \in \Sigma_2} u_2(\sigma_1, \sigma_2') \tag{2.5}$$

([Zinkevich et al., 2007, Eq. 1]).

Eine Approximation eines Nash Gleichgewichts, auch ε-Nash Gleichgewicht genannt, ist ein Strategieprofil σ, welches folgende Ungleichungen erfüllt:

$$u_1(\sigma) + \varepsilon \geq \max_{\sigma_1' \in \Sigma_1} u_1(\sigma_1', \sigma_2), \qquad u_2(\sigma) + \varepsilon \geq \max_{\sigma_2' \in \Sigma_2} u_2(\sigma_1, \sigma_2') \tag{2.6}$$

([Zinkevich et al., 2007, Eq. 2]).

2.2.2 Regret Minimization

Regret misst den Unterschied zwischen dem maximal erreichbaren Nutzen unter Verwendung einer optimalen Strategie und dem tatsächlich erzielten Nutzen.
Um Regret Minimization zu definieren, betrachten wir das wiederholte Spielen eines extensiven Spiels. Sei σ_i^t die von Spieler i in Runde t verwendete Strategie. Der durchschnittliche *overall regret* von Spieler i zum Zeitpunkt T ist

$$R_i^T = \frac{1}{T} \max_{\sigma_i^* \in \Sigma_i} \sum_{t=1}^{T} \big(u_i(\sigma_i^*, \sigma_{-i}^t) - u_i(\sigma^t)\big). \tag{2.7}$$

([Zinkevich et al., 2007, Eq. 3])

Die Durchschnittsstrategie $\bar{\sigma}_i^T$ für Spieler i von Zeit 1 bis T wird für jedes Informationsset $I \in \mathcal{I}_i$ und jede Aktion $a \in A(I)$ definiert als

$$\bar{\sigma}_i^T(I)(a) = \frac{\sum_{t=1}^{T} \pi_i^{\sigma^t}(I)\, \sigma^t(I)(a)}{\sum_{t=1}^{T} \pi_i^{\sigma^t}(I)}. \tag{2.8}$$

([Zinkevich et al., 2007, Eq. 4])

Die Durchschnittsstrategie gewichtet Aktionen proportional zur Erreichbarkeitswahrscheinlichkeit $\pi_i^{\sigma^t}(I)$ des Informationssets I in Runde t.

Es besteht ein wichtiger Zusammenhang zwischen Regret und Nash-Gleichgewichten. In einem Nullsummenspiel gilt: Ist der durchschnittliche overall regret beider Spieler zum Zeitpunkt T kleiner als ε, dann ist $\bar{\sigma}^T$ ein 2ε-Nash-Gleichgewicht ([Zinkevich et al., 2007, Thm. 2]).

Ein Algorithmus zur Bestimmung von σ_i^t ist regret minimierend, wenn der durchschnittliche overall regret von Spieler i unabhängig von der Strategiefolge σ_{-i}^t des Gegners gegen Null konvergiert, während t gegen Unendlich läuft. Daher können regret minimierende Algorithmen im Selfplay verwendet werden, um ein approximatives Nash-Gleichgewicht zu berechnen.

2.2.3 Counterfactual Regret

Die zentrale Idee welche Zinkevich et. al. in ihrem Paper "Regret Minimization in Games with Incomplete Information"präsentieren ist, den gesamten Regret Wert in eine Menge aus additiven Termen zu zerlegen. Diese Terme können dann unabhängig voneinander minimiert werden. Insbesondere wird ein völlig neues regret Konzept mit dem Namen „Counterfactual Regret “eingeführt, welches für jedes Informationsset definiert ist.

Um das Konzept zu erläutern, betrachten wir zunächst ein Informationsset $I \in \mathcal{I}_i$. Der *counterfactual utility* $u_i(\sigma, I)$ ist der erwartete Nutzen unter der Bedingung, dass I erreicht wird und alle Spieler mit σ agieren, während Spieler i so agiert um den Zustand I zu erreichen. Mit $\pi^\sigma(h, h')$ als Wahrscheinlichkeit, von h nach h' zu gelangen, gilt

$$u_i(\sigma, I) = \frac{\sum_{h \in I,\, h' \in Z} \pi_{-i}^\sigma(h)\, \pi^\sigma(h, h')\, u_i(h')}{\pi_{-i}^\sigma(I)}. \tag{2.9}$$

([Zinkevich et al., 2007, Eq. 5])

Für alle $a \in A(I)$ definieren wir $\sigma|_{I \to a}$ als ein Strategieprofil welches identisch zu σ ist, ausser das Spieler i immer Aktion a ausführt wenn er Informationsset I erreicht. Der *immediate counterfactual regret* ist

$$R_{i,\mathrm{imm}}^T(I) = \frac{1}{T} \sum_{t=1}^{T} \max_{a \in A(I)} \pi_{-i}^{\sigma^t}(I) \left(u_i(\sigma^t|_{I \to a}, I) - u_i(\sigma^t, I) \right). \tag{2.10}$$

([Zinkevich et al., 2007, Eq. 6]) Dieser Term misst den Regret im Informationsset I, gewichtet mit der *counterfactual probability*, dass I erreicht werden würde, wenn Spieler i es erzwingen wollte. Da für uns hauptsächlich die positiven regret Werte relevant sind, definieren wir die positiven immediate counterfactual regret Werte als

$$R_{i,\mathrm{imm}}^{T,+}(I) = \max\left(R_{i,\mathrm{imm}}^T(I), 0\right) \tag{2.11}$$

Theorem 3 beschreibt die erste große Erkenntnis des Papers.

$$R_i^T \leq \sum_{I \in \mathcal{I}_i} R_{i,\mathrm{imm}}^{T,+}(I) \tag{2.12}$$

([Zinkevich et al., 2007, Thm. 3])
Das heißt, wenn wir den immediate counterfactual regret minimieren, dann minimieren wir auch den average overall regret.

2.2.4 Regret Matching

Mit folgender Formel berechnen wir den counterfactual regret für eine konkrete Aktion a in einem Informationsset I.

$$R_i^T(I,a) = \frac{1}{T}\sum_{t=1}^{T} \pi_{-i}^{\sigma^t}(I)\left(u_i(\sigma^t|_{I\to a}, I) - u_i(\sigma^t, I)\right) \tag{2.13}$$

([Zinkevich et al., 2007, Eq. 7])

Definieren wir $R_i^{T,+}(I,a) = \max(R_i^T(I,a), 0)$ als positiven Anteil des immediate counterfactual regret für Aktion a.

Die Strategie für Iteration $T+1$ wird dann durch Regret Matching bestimmt:

$$\sigma_i^{T+1}(I)(a) = \begin{cases} \frac{R_i^{T,+}(I,a)}{\sum_{a'\in A(I)} R_i^{T,+}(I,a')} & \text{falls } \sum_{a'\in A(I)} R_i^{T,+}(I,a') > 0 \\ \frac{1}{|A(I)|} & \text{in jedem anderen Fall.} \end{cases} \tag{2.14}$$

([Zinkevich et al., 2007, Eq. 8]) Diese Formel weist Aktionen Wahrscheinlichkeiten proportional zu ihrem positiven Regret für das Nichtspielen dieser Aktion zu. Gibt es keine positiven Regrets, werden alle Aktionen gleichverteilt gewählt.

Theorem 4 zeigt, dass bei Verwendung von Gleichung 8 der immediate counterfactual regret und der overall regret folgendermaßen beschränkt sind:

$$R_{i,\text{imm}}^T(I) \leq \frac{\Delta_{u,i}\sqrt{|A_i|}}{\sqrt{T}}, \tag{2.15}$$

$$R_i^T \leq \frac{\Delta_{u,i}|\mathcal{I}_i|\sqrt{|A_i|}}{\sqrt{T}}, \tag{2.16}$$

wobei $\Delta_{u,i} = \max_z u_i(z) - \min_z u_i(z)$ der Nutzenbereich und $|A_i| = \max_{h:P(h)=i} |A(h)|$ die maximale Anzahl verfügbarer Aktionen für Spieler i ist ([Zinkevich et al., 2007, Thm. 4]). Die Schranke für den average overall regret skaliert linear mit der Anzahl der Informationssets $|\mathcal{I}_i|$, was CFR auch für große Spiele praktikabel macht. Damit fällt der Regret mit $O(1/\sqrt{T})$, und die Durchschnittsstrategie konvergiert im Selbstspiel gegen ein Nash-Gleichgewicht.

2.2.5 CFR Algorithmus

Das CFR-Verfahren verbindet die Komponenten aus den vorherigen Abschnitten zu einer wiederholten Selbstspielprozedur. Zwei Spieler spielen ein Spiel T-mal gegeneinander und bestimmen ihre Strategie in jeder Iteration nach Gleichung 8. Für jedes Informationsset I und jede Aktion a speichern wir den kumulierten Regret $R_i^t(I,a)$ und aktualisieren ihn nach jeder Iteration. Parallel dazu wird die Durchschnittsstrategie gemäß Gleichung 4 aktualisiert. Nach T Iterationen gibt der Algorithmus $(\bar{\sigma}_1^T, \bar{\sigma}_2^T)$ als approximatives Nash-Gleichgewicht zurück.

2.3 Monte Carlo CFR

Der CFR Algorithmus benötigt in jeder Iteration eine vollständige Traversierung des game trees. Monte Carlo CFR ist ein Framework von Algorithmen welchen diesen Aufwand durch verschiedene Sampling Varianten reduziert. In diesem Kapitel wird zuerst die Grundidee des Frameworks erklärt und anschließend genauer auf die einzelnen Sampling Verfahren eingegangen. Abschließend wird ein neues Maß zur Abschätzung der Spielkomplexität eingeführt und die theoretischen Eigenschaften der Algorithmen besprochen.

2.3.1 Allgemeine Definition

MCCFR unterteilt die Menge aller terminalen Historien Z in Teilmengen, welche als Blöcke bezeichnet werden. Die Menge dieser Teilmengen ist definiert als $Q = \{Q_1, \ldots, Q_r\}$. In jeder Iteration wird zufällig ein Block ausgewählt und nur die terminalen Historien dieses Blocks betrachtet.
Die Definition eines Blocks ist abhängig von der Sampling Strategie welche verwendet wird. Im dem Fall das Chance Sampling verwendet wird, enthält ein Block Q_j alle terminal histories mit derselben Sequenz von Zufallsereignissen.
Bei External Sampling hingegen wird ein Block durch eine Kombination aus Zufallsereignissen und Aktionen des Gegners bestimmt.
Die extremste hier genannte Form des Sampling ist das Outcome Sampling, bei welchem Zufallsereignisse, Aktionen des Gegners, sowie private Aktionen zufällig ausgewählt werden.

Sei $q_j > 0$ die Wahrscheinlichkeit, dass Block Q_j in der aktuellen Iteration ausgewählt wird. Für die Summe aller Blockwahrscheinlichkeiten gilt $\sum_{j=1}^{r} q_j = 1$.
Die Wahrscheinlichkeit, dass eine terminal history z in der aktuellen Iteration betrachtet wird, beträgt $q(z) = \sum_{j:z \in Q_j} q_j$.
Als nächstes wird im Paper eine gewichtete Form des Counterfactual Values eingeführt, um zu berücksichtigen, dass ein Block nur mit einer Wahrscheinlichkeit von $q(z)$ erreicht wird. Folgende Formel beschreibt den Counterfactual Value wenn Block j aktualisiert wird.

$$\tilde{v}_i(\sigma, I|j) = \sum_{z \in Q_j \cap Z_I} \frac{1}{q(z)} u_i(z) \pi_{-i}^{\sigma}(z[I]) \pi^{\sigma}(z[I], z). \tag{2.17}$$

([Lanctot et al., 2009, Eq. 6])

Der sampled counterfactual value wurde so konstruiert, dass er im Erwartungswert dem counterfactual value entspricht. Dies wird durch das folgende Lemma formalisiert:

$$\mathbb{E}_{j \sim q_j}[\tilde{v}_i(\sigma, I|j)] = v_i(\sigma, I). \tag{2.18}$$

([Lanctot et al., 2009, Lemma 1]) Dies garantiert, dass MCCFR im Erwartungswert die gleichen Regret-Updates wie CFR durchführt, obwohl nur ein Teil des game trees in jeder Iteration betrachtet wird. Der MCCFR-Algorithmus sampelt in jeder Iteration einen Block und berechnet für jedes betroffene Informationsset die sampled immediate counterfactual regrets. Diese Regrets werden akkumuliert und die Strategie wird in der nächsten Iteration mittels Regret-Matching aktualisiert.

2.3.2 Chance Sampling CFR

Chance Sampling CFR ist ein Spezialfall des MCCFR Frameworks, bei dem nur die Ausgänge von Zufallsereignisse gesampelt werden ([Lanctot et al., 2009]). Das heisst, mit Poker als Beispiel wird in jeder Iteration ein bestimmter Kartendeal per Zufall ausgewählt. Nach dem Sampling wird der gesamte Subtree für diesen Deal traversiert, das heißt, alle möglichen Aktionen beider Spieler werden betrachtet.

2.3.3 External Sampling MCCFR

In External Sampling MCCFR werden nur die Aktionen des Gegners und des Zufalls gesampelt, also die Entscheidungen, die extern zum betrachteten Spieler sind. Für jede reine Strategie τ von Gegner und Zufall wird ein Block $Q_\tau \in Q$ definiert. Die Strategie τ ist eine deterministische Abbildung von Informationssets $I \in \mathcal{I}_c \cup \mathcal{I}_{N\setminus\{i\}}$ zu Aktionen $A(I)$.

Die Blockwahrscheinlichkeiten werden basierend auf den Verteilungen f_c und σ_{-i} zugewiesen:

$$q_\tau = \prod_{I \in \mathcal{I}_c} f_c(\tau(I)|I) \prod_{I \in \mathcal{I}_{N\setminus\{i\}}} \sigma_{-i}(\tau(I)|I). \tag{2.19}$$

Der Block Q_τ enthält alle terminal histories z, die mit τ konsistent sind, das heißt, wenn ha ein Präfix von z ist mit $h \in I$ für ein $I \in \mathcal{I}_{-i}$, dann gilt $\tau(I) = a$. In der Praxis wird τ nicht explizit gesampelt, sondern die einzelnen Aktionen werden nur bei Bedarf gesampelt.

Diese Blockwahrscheinlichkeiten ergeben $q(z) = \pi^\sigma_{-i}(z)$. Der Algorithmus iteriert über jeden Spieler $i \in N$ und führt für jeden eine Post-Order Tiefensuche durch den Game Tree durch. Während der Traversierung werden Aktionen an jeder History h gesampelt, für die $P(h) \neq i$ gilt. Diese gesampelten Entscheidungen werden gespeichert, sodass die gleichen Aktionen für alle Histories im selben Informationsset verwendet werden. Aufgrund von perfect recall kann während dieser Traversierung nie mehr als eine History aus dem selben Informationsset besucht werden.

Für jedes besuchte Informationsset werden die sampled counterfactual regrets berechnet und zu den Gesamtregrets hinzugefügt:

$$\tilde{r}(I, a) = (1 - \sigma(a|I)) \sum_{z \in Q_\tau \cap Z_I} u_i(z)\pi^\sigma_i(z[I]a, z). \tag{2.20}$$

([Lanctot et al., 2009, Eq. 11]) Die Summation kann während der Traversierung effizient berechnet werden, indem für jede History eine gewichtete Summe der Utilities aller von dieser History erreichbaren terminal histories aufrechterhalten wird.

2.3.4 Outcome Sampling MCCFR

Bei Outcome Sampling MCCFR wird in jeder Iteration nur eine einzelne terminal history gesampelt. Jeder Block $Q \in Q$ enthält genau eine terminal history, das heißt $\forall Q \in Q$:

$|Q| = 1$. Dies ist der extremste Fall des Samplings, da in jeder Iteration nur ein einziger Pfad durch den game tree betrachtet wird.

Die Sampling-Wahrscheinlichkeiten q_j müssen eine Verteilung über die terminal histories spezifizieren. Dazu wird eine *sampling policy* σ' verwendet, sodass $q(z) = \pi^{\sigma'}(z)$ gilt. Jede Wahl einer sampling policy induziert eine bestimmte Verteilung über die Blockwahrscheinlichkeiten. Solange $\sigma'_i(a|I) > \epsilon$ für ein $\epsilon > 0$ gilt, existiert ein $\delta > 0$ mit $q(z) > \delta$, wodurch sichergestellt wird, dass der sampled counterfactual value wohldefiniert ist.

Der Algorithmus funktioniert, indem eine terminal history z gemäß der sampling policy σ' gesampelt wird und dabei $\pi^{\sigma'}(z)$ gespeichert wird. Die einzelne History wird dann vorwärts traversiert, um für jeden Präfix h von z die Wahrscheinlichkeit $\pi_i^{\sigma}(h)$ zu berechnen, mit der Spieler i diesen Präfix erreicht. Anschließend wird die History rückwärts traversiert, um für jeden Präfix h die Wahrscheinlichkeit $\pi_i^{\sigma}(h, z)$ zu berechnen, mit der Spieler i die verbleibenden Aktionen der History spielt.

Während der Rückwärtstraversierung werden die sampled counterfactual regrets an jedem besuchten Informationsset berechnet und zu den Gesamtregrets hinzugefügt:

$$\tilde{r}(I, a) = \begin{cases} w_I \cdot (1 - \sigma(a|z[I])) & \text{falls } (z[I]a) \sqsubset z \\ -w_I \cdot \sigma(a|z[I]) & \text{sonst} \end{cases}, \tag{2.21}$$

wobei

$$w_I = \frac{u_i(z)\pi_{-i}^{\sigma}(z)\pi_i^{\sigma}(z[I]a, z)}{\pi^{\sigma'}(z)}. \tag{2.22}$$

([Lanctot et al., 2009, Eq. 10])

Ein wichtiger Vorteil von Outcome Sampling MCCFR ist, dass wenn die terminal history gemäß der Strategie des Gegners gesampelt wird, das heißt $\sigma'_{-i} = \sigma_{-i}$, dann benötigt das Update keine explizite Kenntnis von σ_{-i}, da sich dieser Term in w_I aufhebt. In diesem Fall wird w_I zu $u_i(z)\pi_i^{\sigma'}(z[I], z)/\pi_i^{\sigma'}(z)$. Daher kann Outcome Sampling MCCFR für *online regret minimization* verwendet werden, wenn die Strategie des Gegners nicht bekannt ist. Dazu muss der eigene Spieler seine Aktionen so wählen, dass $\sigma'_i \approx \sigma_i^t$ gilt, jedoch mit etwas Exploration, um $q_j \geq \delta > 0$ zu garantieren. Durch die Balance zwischen dem durch Exploration verursachten Regret und dem durch ein kleines δ verursachten Regret kann der average overall regret beschränkt werden, solange die Anzahl der Spiele T im Voraus bekannt ist ([Lanctot et al., 2009]).

2.3.5 Theoretische Eigenschaften

Der M Wert

Um die Regret Bounds für MCCFR Varianten zu formulieren, wird ein strukturelles Maß der Spielkomplexität eingeführt: der M Wert. Dieser Wert hängt von der spezifischen Struktur des extensiven Spiels ab und ermöglicht eine präzisere Abschätzung der Konvergenzrate als die einfache Anzahl der Information Sets.

Sei $\vec{a}_i$ eine Teilsequenz einer Historie, die nur die Aktionen von Spieler i in dieser Historie enthält. Sei $\vec{A}_i$ die Menge aller solcher Aktionssequenzen von Spieler i. Für eine

Aktionssequenz $\vec{a}_i$ sei $\mathcal{I}_i(\vec{a}_i)$ die Menge aller Information Sets, bei denen die Aktionssequenz von Spieler i bis zu diesem Information Set genau $\vec{a}_i$ ist. Der M Wert für Spieler i ist dann definiert als

$$M_i = \sum_{\vec{a}_i \in \vec{A}_i} \sqrt{|\mathcal{I}_i(\vec{a}_i)|}. \tag{2.23}$$

([Lanctot et al., 2009])

Der M Wert summiert also über alle möglichen Aktionssequenzen von Spieler i die Wurzel der Anzahl der Information Sets, die zu dieser Sequenz gehören. Dies erfasst, wie sich die Information Sets über die verschiedenen Aktionssequenzen verteilen.

Für den M Wert gilt die folgende Ungleichung:

$$\sqrt{|\mathcal{I}_i|} \leq M_i \leq |\mathcal{I}_i|, \tag{2.24}$$

wobei beide Seiten dieser Schranke von bestimmten Spielen erreicht werden können ([Lanctot et al., 2009]).

Die untere Schranke $\sqrt{|\mathcal{I}_i|}$ wird erreicht, wenn alle Information Sets zu derselben Aktionssequenz gehören. Die obere Schranke $|\mathcal{I}_i|$ wird erreicht, wenn jede Aktionssequenz zu genau einem Information Set führt.

Als Beispiel betrachten wir Kuhn Poker. Beide Spieler haben jeweils sechs Information Sets: $|\mathcal{I}_0| = |\mathcal{I}_1| = 6$.

Für Spieler 0 gibt es zwei Aktionssequenzen mit Information Sets: die leere Sequenz [] mit drei Information Sets $(J, (), 0)$, $(Q, (), 0)$, $(K, (), 0)$ am Spielbeginn, sowie die Sequenz $['check']$ mit drei Information Sets $(J, ('check', 'bet'), 0)$, $(Q, ('check', 'bet'), 0)$, $(K, ('check', 'bet'), 0)$ nach einem Check von Spieler 0 und einem Bet von Spieler 1. Somit gilt $M_0 = \sqrt{3} + \sqrt{3} = 2\sqrt{3} \approx 3.46$.

Für Spieler 1 gibt es nur eine Aktionssequenz mit Information Sets: die leere Sequenz [] mit sechs Information Sets, nämlich drei nach einem Check von Spieler 0 und drei nach einem Bet von Spieler 0. Somit gilt $M_1 = \sqrt{6} \approx 2.45$.

Die Verifikation der Schranken ergibt: $\sqrt{6} \approx 2.45 \leq M_0 = 3.46 \leq 6$ und $\sqrt{6} \approx 2.45 \leq M_1 = 2.45 \leq 6$. Für Spieler 1 wird die untere Schranke erreicht, da alle sechs Information Sets zur selben Aktionssequenz gehören. Für Spieler 0 liegt M_0 zwischen den Schranken, da die Information Sets auf zwei verschiedene Aktionssequenzen verteilt sind.

Der M Wert wird sowohl in den folgenden Regret Bounds für Vanilla CFR als auch für MCCFR verwendet.

Regret Bounds

Mit Hilfe des M Werts können präzisere Regret Bounds für Vanilla CFR formuliert werden.

$$R_i^T \leq \Delta_{u,i} M_i \sqrt{|A_i|} / \sqrt{T}, \tag{2.25}$$

([Lanctot et al., 2009, Thm. 3]) wobei $\Delta_{u,i} = \max_z u_i(z) - \min_z u_i(z)$ der Nutzenbereich für Spieler i ist und $|A_i| = \max_{h:P(h)=i} |A(h)|$ die maximale Anzahl verfügbarer Aktionen für Spieler i bezeichnet.

Diese Schranke verbessert die ursprüngliche Bound aus Theorem 4 des Zinkevich Papers, die $|\mathcal{I}_i|$ anstelle von M_i verwendet. Da $M_i \leq |\mathcal{I}_i|$ gilt, ist die neue Schranke mindestens so gut wie die ursprüngliche und oft deutlich besser. Die Konvergenzrate bleibt bei $O(1/\sqrt{T})$, wobei der konstante Faktor durch die strukturabhängige Komplexität M_i statt der einfachen Anzahl der Information Sets bestimmt wird.

Für die MCCFR Varianten können probabilistische Regret Bounds angegeben werden. External Sampling MCCFR benötigt nur einen konstanten Faktor mehr Iterationen als Vanilla CFR. Für jeden Parameter $p \in (0, 1]$ gilt mit Wahrscheinlichkeit mindestens $1-p$:

$$R_i^T \leq \left(1 + \sqrt{\frac{2}{p}}\right) \Delta_{u,i} M_i \sqrt{|A_i|}/\sqrt{T}. \tag{2.26}$$

([Lanctot et al., 2009, Thm. 4])

Obwohl External Sampling die gleiche Ordnung von Iterationen benötigt wie Vanilla CFR, muss der Algorithmus in jeder Iteration nur einen Bruchteil des Spielbaums traversieren. Für ausgewogene Spiele, in denen die Spieler ungefähr gleich viele Entscheidungen treffen, betragen die Iterationskosten von External Sampling $O(\sqrt{|H|})$, während Vanilla CFR $O(|H|)$ benötigt. Dies bedeutet, dass External Sampling MCCFR asymptotisch weniger Zeit benötigt, um ein approximatives Gleichgewicht zu berechnen als Vanilla CFR ([Lanctot et al., 2009]).

Für Outcome Sampling MCCFR kann ebenfalls ein probabilistisches Regret Bound angegeben werden. Falls für jede terminal history $z \in Z$ entweder $\pi_{-i}^{\sigma}(z) = 0$ oder $q(z) \geq \delta > 0$ zu jedem Zeitpunkt gilt, dann gilt für jeden Parameter $p \in (0, 1]$ mit Wahrscheinlichkeit mindestens $1 - p$:

$$R_i^T \leq \left(1 + \sqrt{\frac{2}{p}} \cdot \frac{1}{\sqrt{\delta}}\right) \Delta_{u,i} M_i \sqrt{|A_i|}/\sqrt{T}. \tag{2.27}$$

([Lanctot et al., 2009, Thm. 5]) Im Vergleich zu External Sampling enthält diese Schranke einen zusätzlichen Faktor $\frac{1}{\sqrt{\delta}}$, der von der Wahl der sampling policy abhängt. Je größer δ ist, desto besser ist die Schranke, was bedeutet, dass die sampling policy eine ausreichend große Wahrscheinlichkeit für alle relevanten terminal histories gewährleisten sollte.

2.4 CFR+

2.4.1 Unterschiede zu Vanilla CFR

CFR+ ist eine Variante von CFR, die deutlich schneller konvergiert als Standard CFR. Cepheus, das erste Programm welches Heads up no Limit Holdem erfolgreich gelöst hat verwendet diese.

Erste Änderung: CFR+ verwendet eine linear gewichtete Durchschnittsstrategie statt der uniformen Durchschnittsstrategie von CFR. Die gewichtete Durchschnittsstrategie ist definiert als $\bar{\sigma}_p^T = 2/(T^2 + T) \sum_{t=1}^{T} t\sigma_p^t$, wobei spätere Iterationen stärker gewichtet werden.

CFR+ verwendet wie Vanilla CFR kein Sampling. Viele andere CFR Implementierungen nutzen Sampling Techniken zur Beschleunigung, während CFR+ und Vanilla CFR den gesamten Spielbaum in jeder Iteration traversieren.

Zweite Änderung: CFR+ führt alternierende Updates durch. Im Gegensatz zum ursprünglichen CFR, das die Regrets beider Spieler simultan aktualisiert, aktualisiert CFR+ die Spieler abwechselnd.

Dritte und wichtigste Änderung: CFR+ verwendet Regret Matching+ anstelle von Regret Matching. Regret Matching+ setzt negative Regrets auf null zurück, statt sie zu ignorieren, was zu besseren Tracking Regret Eigenschaften führt.

2.4.2 Regret Matching+

Regret Matching+ ist ein Regret minimierender Algorithmus, der sehr ähnlich zu Regret Matching operiert. Der entscheidende Unterschied liegt im Umgang mit negativen Regrets: Während Regret Matching Aktionen mit akkumuliertem negativen Regret ignoriert, setzt Regret Matching+ jeden akkumulierten negativen Regret aktiv auf null zurück.

Formal speichert Regret Matching+ nicht die Regrets $R^t(a)$, sondern verfolgt einen regret ähnlichen Wert:

$$Q^t(a) = \left(Q^{t-1}(a) + \Delta R^t(a)\right)^+, \tag{2.28}$$

wobei $x^+ = \max(x, 0)$ den positiven Anteil bezeichnet. Die Strategie basiert auf diesen Werten:

$$\sigma^t(a) = \frac{Q^{t-1}(a)}{\sum_{b \in A} Q^{t-1}(b)}. \tag{2.29}$$

([Tammelin et al., 2015])

Theorem 1 liefert eine Regret Bound für Regret Matching+. Gegeben sei eine Menge von Aktionen A und eine Sequenz von T Wertfunktionen $v^t : A \to \mathbb{R}$. Es existiere eine Schranke L, sodass $|v^t(a) - v^t(b)| \leq L$ für alle t und $a, b \in A$ gilt. Ein Agent, der nach dem Regret Matching+ Algorithmus handelt, hat dann einen Regret von höchstens

$$R^T \leq L\sqrt{|A|T}. \tag{2.30}$$

([Tammelin et al., 2015, Thm. 1])

Diese Schranke ist identisch mit der Regret Bound von Regret Matching. Folglich hat CFR+ die gleiche theoretische Regret Bound wie CFR. In der Praxis konvergiert CFR+ jedoch deutlich schneller als CFR, was teilweise durch die besseren Tracking Regret Eigenschaften von Regret Matching+ erklärt werden kann.

Die empirische Überlegenheit von Regret Matching+ hat eine intuitive Erklärung. Regret Matching+ übertrifft Regret Matching insbesondere dann, wenn sich die beste Aktion plötzlich ändert. Bei Regret Matching muss der Algorithmus warten, bis eine zuvor schlechte Aktion sich beweist, und muss dabei ihr gesamtes akkumuliertes negatives Regret überwinden. Regret Matching+ kann dagegen sofort die neue beste Aktion spielen, da negatives Regret auf null zurückgesetzt wird und nicht erst überwunden werden muss.

2.4.3 Tracking Regret

Tracking Regret ist ein von Herbster und Warmuth eingeführtes Konzept [Herbster and Warmuth, 1998], das die Performance im Nachhinein gegen eine größere Menge von Alternativen betrachtet. Während Standard Regret nur gegen statische Strategien vergleicht, die immer die gleiche Aktion wählen, erlaubt Tracking Regret den Vergleich gegen Strategien, die ihre Aktion höchstens $(k-1)$ Mal ändern können.

Regret Matching hat sehr schlechte Tracking Regret Eigenschaften. Der Algorithmus kann lineares Regret haben, selbst wenn die Vergleichsstrategie nur einmal wechselt ($k = 2$). Im Gegensatz dazu ist Regret Matching+ der erste Regret Matching basierte Algorithmus mit sublinearem Tracking Regret.

Theorem 2 formalisiert diese Eigenschaft. Für alternative Strategien, die bis zu $(k-1)$ Mal wechseln können, hat Regret Matching+ eine Regret Schranke von

$$R^T \leq kL\sqrt{|A|T}. \tag{2.31}$$

([Tammelin et al., 2015, Thm. 2]) Diese Schranke zeigt, dass der Regret linear mit der Anzahl der Wechsel k skaliert, aber sublinear mit der Anzahl der Iterationen T bleibt.

2.4.4 Linear Weighted Average

CFR+ verwendet eine linear gewichtete Durchschnittsstrategie anstelle der uniformen Durchschnittsstrategie von CFR. Die linear gewichtete Durchschnittsstrategie ist definiert als

$$\bar{\sigma}_p^T = \frac{2}{T^2+T}\sum_{t=1}^{T} t\sigma_p^t, \tag{2.32}$$

wobei spätere Iterationen stärker gewichtet werden.

Theorem 3 zeigt, dass diese Strategie zu einem ε-Nash Equilibrium konvergiert. Für eine Sequenz von T Verhaltensstrategieprofilen σ^t aus CFR+ für T Iterationen in einem extensiven Spiel, wobei $\max|v_p(l) - v_p(l')| \leq L$ für alle Spieler p und terminale Historien l, l' gilt, ist die linear gewichtete Durchschnittsstrategie ein $2(|\mathcal{I}_1|+|\mathcal{I}_2|)L\sqrt{k}/\sqrt{T}$-Nash Equilibrium ([Tammelin et al., 2015, Thm. 3]).

Die Schranke $\varepsilon = 2(|\mathcal{I}_1|+|\mathcal{I}_2|)L\sqrt{k}/\sqrt{T}$ setzt sich aus folgenden Komponenten zusammen: $|\mathcal{I}_1|+|\mathcal{I}_2|$ ist die Summe der Information Sets beider Spieler, L ist der Nutzenbereich als maximaler Unterschied zwischen terminalen Historien, und $k = \max_{I\in\mathcal{I}}|A(I)|$ ist die maximale Anzahl Aktionen in einem Information Set. Die Schranke impliziert eine Konvergenzrate von $O(1/\sqrt{T})$, die asymptotisch identisch mit der Rate von uniform weighting ist. Theorem 3 gilt nicht für CFR, und im Gegensatz zu CFR+, wo linear weighting die Performance verbessert, verschlechtert linear weighting die Performance von CFR. In der Praxis erreicht die aktuelle Strategie in CFR+ oft bereits eine gute Approximation zum Nash Equilibrium, sodass das aggressive Weighting die Konvergenz weiter beschleunigen kann ([Tammelin et al., 2015]).

2.5 Hold'em Games

In diesem Kapitel stelle ich vor, welche Pokervarianten im Rahmen dieser Arbeit mittels CFR gelöst werden sollen. Hierbei erkläre ich zunächst grundlegend wodurch sich die Untergruppierung von Pokerspielen, Hold'em Spiele, auszeichnen und stelle dann einige bekannte Varianten vor. Denn, wenn, man die Grundstruktur von Hold'em Spielen definiert hat, ist es einfach diese Struktur zu erweitern und alle folgenden Poker Hold'em Varianten darzustellen. Anschließend beschreibe ich die Varianten welche in dieser Arbeit gelöst werden und warum ich diese Auswahl getroffen habe.

Ich beschäftige mich in dieser Arbeit ausschließlich mit Heads-Up Limit Versionen von Hold'em Spielen. Heads-Up bedeutet, dass das Spiel nur zwei Teilnehmer beinhaltet. Die Klassifikation Limit bezieht sich darauf, dass die Setzgrößen der Spieler auf vorher festgelegte Beträge beschränkt sind. Diese zwei Einschränkungen reduzieren die Komplexität enorm. Die folgende Definition gilt für jegliche Heads-Up Limit Hold'em Spiele.

Eine Iteration eines Hold'em Spiels nennt man eine Hand. Eine Hand widerum besteht aus mehreren Runden. In der ersten Runde wird eine bestimmte Anzahl an privaten Karten (Hole Cards) an die zwei Teilnehmer verteilt. In *jeder* Runde wird eine bestimmte Anzahl (0 auch möglich), an öffentlichen Karten (Board Cards) aufgedeckt.

Nachdem Karten ausgeteilt oder aufgedeckt wurden, folgt immer eine Setz Runde, in welcher die Spieler abwechselnd Entscheidungen treffen. Ihnen stehen grundlegend 3 Auswahlmöglichkeiten zur Verfügung: "fold, call und raise„. Die Begrifflichkeiten können sich abhängig von der Quelle und dem Spiel etwas unterscheiden.
Wählt ein Spieler die Aktion *fold*, endet die Hand sofort und der andere Spieler gewinnt den Pot. Der Pot ist die Ansammlung aller Einsätze die im Verlauf der Hand gesetzt wurden.
Bei einem *call*, setzt er so viele Chips in den Pot, bis er genauso viele Chips in den Pot eingezahlt hat wie der andere Spieler. Die Anzahl an Chips kann auch 0 betragen. In Pokervarianten welche zu Unterhaltungs und nicht zu Forschungszwecken gespielt werden, nennt man das dann *check*.
Bei der Aktion *raise*, setzt der Spieler zunächst genauso viel Chips in den Pot wie sein Gegner, analog zum *call*. Anschließend setzt er dann zusätzlich noch einen durch die Spielregeln festgelegten Betrag an Chips.

Die Spieler treffen solange abwechselnd Entscheidungen bis entweder ein Spieler folded, in diesem Fall endet die Hand sofort, oder bis ein Spieler called (solange es nicht die erste Aktion der Runde ist). In dem Fall das ein Spieler called, endet nur die Runde und nicht die Hand. Um eine endlose Abfolge aus Raises zu vermeiden, gibt es eine Obergrenze für die Anzahl an Raises nacheinander ausgeführt werden dürfen. Wenn das Setzlimit erreicht ist, bleiben dem Spieler welcher am Zug ist, nur die Optionen Call und Fold. Wenn bis zum Ende der finalen Setzrunde kein Spieler gefolded hat, kommt es zu einem *Showdown*. Bei einem Showdown offenbaren beide Spieler ihre Hole Cards und bilden aus allen zu Verfügung stehenden Karten (Hole + Board Cards) die bestmögliche Pokerhand. Der Spieler mit der stärkeren Hand gewinnt den Pot, welche möglichen Pokerhände es gibt, und welcher Rangordnung diese folgen, hängt von der Variante des Spiels ab. Eine Übersicht über die verschiedenen Pokerhände und deren Bedeutung findet sich unter `https://en.wikipedia.org/wiki/List_of_poker_hands`. [Southey et al., 2005]

Da wir jetzt eine grundlegende Definition eines Heads-Up Limit Hold'em Spiels haben, können wir nun, durch anpassen einzelner Parameter jegliche Varianten definieren. Die relevantesten Aspekte sind: Die Anzahl der Hole und Board Cards, die Anzahl der Setzrunden, dem Setzlimit pro Runde, den im Deck enthaltenden Karten, die möglichen Pokerhände, die festgelegten Setzgrößen und noch einiges mehr.

2.5.1 Kuhn Poker

Die simpelste definierte Pokervariante ist One Card Poker auch Kuhn Poker gennant. Der Name Kuhn Poker stammt durch den Erfinder dieses Spiels Harald Kuhn, welcher es in seinem Paper aus dem Jahr 1951 mit dem Titel "Simplified Two-Person Poker „beschrieb.
Kuhn Poker wird mit einem Kartendeck bestehend aus 3 Karten gespielt. In seinem Paper sind die Karten mit 1,2 und 3 bennant, wobei 1 die schlechteste und 3 die beste Karte ist. Für diese Arbeit wird die Notation J, Q, K verwendet, die den Rängen eines Standard Kartenspiels entspricht.

Zu Beginn zahlen beide Spieler einen Pflichteinsatz in Höhe eines Chips in den Pot, dies wird auch Ante genannt. Beide Spieler erhalten eine private Karte und es werden keine öffentlichen Karten ausgeteilt. Nach dem austeilen der privaten Karte startet die erste und einzige Setzrunde, in welcher die Spieler jeweils einen Chip in den Pot setzen dürfen, womit das Setzlimit bei Eins liegt. Im Falle eines Showdowns, gewinnt die höhere Karte $J < Q < K$.

Kuhn definiert in seinem Paper auch noch andere Versionen seines Spiels indem er das Verhältnis zwischen Ante und Setzgröße anpasst. Der eben beschriebene Fall in welchem der Ante genauso groß ist wie die Setzgröße, wird von ihm Fall 2 genannt. Fall 1 liegt vor, wenn die Setzgröße kleiner als der Ante ist. Fall 3 tritt ein, wenn der Ante kleiner als die Setzgröße ist und die Setzgröße kleiner als das Doppelte des Antes ist. Fall 4 liegt vor, wenn die Setzgröße dem Doppelten des Antes entspricht. [Kuhn, 1951]

2.5.2 Leduc Hold'em

Leduc Hold'em [Southey et al., 2005] ist eine vereinfachte Hold'em Variante für zwei Spieler.

Leduc Hold'em wird mit einem Kartendeck bestehend aus zwei Suits mit drei Karten pro Suit gespielt, insgesamt sechs Karten. Die Karten Notation verwendet Rank und Suit, beispielsweise Js, Jh, Qs, Qh, Ks, Kh.

Das Spiel besteht aus zwei Runden. In der ersten Runde erhält jeder Spieler eine private Karte. In der zweiten Runde wird eine öffentliche Board Karte aufgedeckt.

Zu Beginn zahlen beide Spieler einen Ante von einem Chip in den Pot. Es gibt ein Maximum von zwei Bets pro Runde. Die Setzgrößen betragen 2 Chips in der ersten Runde und 4 Chips in der zweiten Runde.

Die möglichen Pokerhände sind entweder ein Paar oder nur eine High Card. Ein paar gewinnt gegen eine High Card.

2.5.3 Zwölf Karten Variante

Die folgende Pokervariante ist von mir selbst entworfen worden, als eine Zwischenstufe der Komplexität zwischen Leduc Hold'em und Rhode Island Hold'em. Die 12 Karten Variante verwendet ein Deck mit zwölf Karten: J, Q, K und A in drei Suits (s, h, d).

Es gibt drei Runden. In der ersten Runde erhält jeder Spieler eine private Karte. In der zweiten und dritten Runde wird jeweils eine öffentliche Board Karte aufgedeckt.

Es gibt ein Maximum von zwei Bets pro Runde. Die Setzgrößen betragen 2 Chips in der ersten Runde, 4 Chips in der zweiten Runde und 8 Chips in der dritten Runde. Zu Beginn zahlen beide Spieler einen Ante von 1 Chip in den Pot.

Das Spiel endet nach der dritten Runde mit einem Showdown. Die Hand besteht aus der Kombination der privaten Karte des Spielers und den beiden öffentlichen Board Karten. Die Hand Rankings sind: Three of a Kind schlägt ein Paar, ein Paar schlägt High Card.

2.5.4 Rhode Island Hold'em

Rhode Island Hold'em [Shi and Littman, 2001] wurde von Shi und Littman im Jahr 2001 als Testbed für AI Forschung entwickelt.

Rhode Island Hold'em verwendet ein Standard Kartendeck mit 52 Karten. Zu Beginn zahlen beide Spieler einen Ante von 5 Chips in den Pot. Jeder Spieler erhält eine private Karte.

Das Spiel besteht aus drei Runden. Die erste Runde findet nach dem Austeilen der privaten Karten statt. Die Bet Size beträgt 10 Chips und es gibt ein Limit von drei Raises pro Runde. Nach der ersten Runde wird eine öffentliche Board Karte, der Flop, aufgedeckt. Die zweite Runde findet nach dem Flop statt. Die Bet Size beträgt 20 Chips. Nach der zweiten Runde wird eine weitere öffentliche Board Karte, der Turn, aufgedeckt. Die dritte und finale Runde findet nach dem Turn statt. Die Bet Size beträgt ebenfalls 20 Chips.

Beim Showdown bildet jeder Spieler die beste 3 Card Poker Hand aus seiner privaten Karte und den beiden öffentlichen Board Karten. Die Hand Rankings für 3 Card Poker unterscheiden sich von 5 Card Poker. Three of a Kind schlägt Straight und Flush. Straight schlägt Flush. Flush schlägt Pair und Pair schlägt High Card. Bei einem Unentschieden wird der Pot gleichmäßig geteilt.

2.5.5 Limit Texas Hold'em

Texas Hold'em [Southey et al., 2005] ist das häufigste Format für Hold'em.

Texas Hold'em verwendet ein Standard Kartendeck mit 52 Karten, bestehend aus 2 bis Ass in vier Suits.

Das Spiel besteht aus vier Betting Runden. In der ersten Runde erhalten die Spieler jeweils zwei private Karten. In der zweiten Runde, dem Flop, werden drei Board Karten

aufgedeckt. In der dritten Runde, dem Turn, wird eine vierte Board Karte aufgedeckt. In der vierten Runde, dem River, wird eine fünfte Board Karte aufgedeckt.

Es gibt ein Maximum von vier Bets pro Runde. Die festgelegten Bet Sizes betragen 10 Chips in den ersten beiden Runden und 20 Chips in den letzten beiden Runden. In diesem Variation beginnt das Spiel nicht mit einem Ante, bei dem beide Spieler die gleiche Anzahl an Chips in den Pot zahlen, sondern mit einer Struktur die man Blinds nennt. Dabei zahlt der erste Spieler 5 Chips in den Pot und der zweite 10 Chips.

Die möglichen Pokerhände sind Royal Flush, Straight Flush, Four of a Kind, Full House, Flush, Straight, Three of a Kind, Two Pair, One Pair und High Card. Diese Vielfalt an möglichen Händen trägt zur hohen Komplexität des Spiels bei.

Kapitel 3

Analyse

In diesem Kapitel lege ich dar, welche Komponenten Teil dieser Arbeit sind und welche Anforderungen an diese gestellt werden. Zunächst nenne ich die zu lösenden Spielvarianten und begründe, warum diese ausgewählt wurden. Danach stelle ich die Algorithmen vor, welche verwendet werden. Gegen Ende des Kapitels präsentiere ich die Evaluationsmethoden, welche verwendet werden, um festzustellen, ob die errechneten Strategien ein approximatives Nash Gleichgewicht darstellen.

3.1 Spielvarianten

Im Rahmen meines Exposés hatte ich ursprünglich geplant, die Funktionalität von CFR anhand von drei Pokervarianten zu untersuchen: Kuhn Poker, Leduc Hold'em und eine selbst entwickelte Pokervariante mit einem 12 Karten Deck. Ausserdem war geplant, die Funktionalität des Pokerspiels und des CFR Algorithmus gesondert zu implementieren. Dadurch kann das Projekt später ohne große Probleme um weitere Spielvarianten oder andere Algorithmen erweitert werden. Zur Evaluation soll der Best Response Algorithmus sowie der Erwartungswert im Selfplay verwendet werden.

Die Auswahl der Pokervarianten Kuhn Poker und Leduc Holdem wurde getroffen, da diese 2 Spiele die Pokervarianten mit der geringsten Komplexität darstellen und sich deshalb exzellent für Forschungszwecke eignen. Da ich mir im Klaren war, dass ich mit meinen technischen Gegebenheiten nicht in der Lage sein werde eine komplexe Pokervariante wie Limit Holdem zu lösen brauchte ich eine Stufe dazwischen. Zu diesem Zeitpunkt waren mir die Foschungsspiele Rhode Island Holdem und Royal Holdem noch nicht bekannt. Aus diesem Grund habe ich mir eine eigene Pokervariante mit moderater Komplexität ausgedacht welche sich in der Komplexitätsleiter als drittes ansiedelt. Die Varianten Royal Holdem und Rhode Island Holdem besitzen eine weitaus größere Komplexität als meine eigene Kreation. Ich mache mir keine großen Hoffnungen diese Varianten erfolgreich zu lösen, sie werden jedoch trotzdem Implementiert, da der Aufwand sich in Grenzen hält.

3.2 CFR Solver

In dieser Arbeit werden drei verschiedene Varianten von CFR Algorithmen implementiert: Vanilla CFR, CFR+ und MCCFR mit External Sampling. Vanilla CFR dient als Baseline für den Vergleich aller Varianten und ermöglicht es, die Verbesserungen der anderen Algorithmen zu quantifizieren. MCCFR wurde ausgewählt, um eine Variante zu untersuchen, die nicht den gesamten Game Tree explizit besucht, sondern mittels Sampling arbeitet. CFR+ wurde implementiert, da es die Grundlage für die erfolgreiche Poker KI Libratus bildet, welche in den letzten Jahren bedeutende Erfolge in diesem Bereich erzielt hat.

3.3 Evaluationsmethoden

Zur Evaluation der berechneten Strategien werden zwei Hauptmethoden verwendet. Exploitability Tests mit einem Best Response Agent und die Berechnung des Erwartungswerts im Selfplay.

Der Exploitability Test mit einem Best Response Agent misst, wie stark eine Strategie ausgenutzt werden kann. Ein Best Response Agent spielt optimal gegen die zu evaluierende Strategie. Die Exploitability ist definiert als der erwartete Gewinn des Best Response Agents minus dem erwarteten Gewinn bei einem Nash Gleichgewicht. Eine niedrige Exploitability deutet darauf hin, dass die Strategie nahe an einem Nash Gleichgewicht liegt.

Die Berechnung des Erwartungswerts im Selfplay ermöglicht es, die Performance der Strategie zu bewerten, wenn beide Spieler die gleiche Strategie verwenden. Dies gibt Aufschluss über die Qualität der Strategie in einem symmetrischen Setting.

Zusätzlich werden Konvergenzplots erstellt, um die Entwicklung der Strategiequalität über die Iterationen hinweg zu visualisieren. Diese werden erstellt, indem in regelmäßigen Abständen, die Exploitability mittels des Best Response Agents ermittelt wird.

In diesem Kapitel wurden die Komponenten dieser Arbeit vorgestellt und die Anforderungen an diese definiert. Es wurden die zu untersuchenden Spielvarianten, die zu implementierenden CFR Algorithmen und die verwendeten Evaluationsmethoden dargelegt. Im folgenden Kapitel beschreibe ich wie die Architektur der Software aussieht.

Kapitel 4

Design und Architektur

In diesem Kapitel wird die Architektur des Softwareprojekts beschrieben. Es werden die Designentscheidungen erläutert und die Struktur der einzelnen Komponenten anhand von UML Diagrammen dargestellt.

Ein zentrales Designprinzip des Codes ist die Trennung der Game Engine vom CFR Algorithmus. Die Game Engine wird als separate Entität implementiert, die die Spiellogik und Spielzustandsverwaltung übernimmt. Der CFR Algorithmus nutzt die öffentlichen Methoden der Game Engine, ohne direkten Zugriff auf die interne Implementierung der Spiellogik zu haben.

Diese Architektur ermöglicht es, das Projekt später ohne große Probleme um weitere Spielvarianten oder andere Algorithmen zu erweitern. Neue Pokervarianten können implementiert werden, ohne den CFR Algorithmus zu ändern, und neue Algorithmen können hinzugefügt werden, ohne die Game Engine zu modifizieren. Diese Trennung von Algorithmus und Spiellogik erhöht die Wartbarkeit und Erweiterbarkeit des Systems.

4.1 Game Environment

In diesem Kapitel wird der Aufbau der Spielumgebung mithilfe von Klassendiagrammen beschrieben. Die Spielumgebung ist für die Logik des Pokerspiels zuständig, sowie dazu den Spielzustand zu verwalten.

Eine Spielumgebung ist unterteilt in die Klassen Player(2 Teilnehmer des Spiels), Dealer(Verwaltet Deck), Judger(bestimmt den Gewinner) und Game(Verwendet andere Komponenten). Dies wird bei allen Varianten ausser Kuhn Poker zusätzlich noch durch eine Round Klasse erweitert, welche den Übergang zwischen Setzrunden steuert. Diese Architektur wurde von RLCard übernommen.

Abbildung 4.1 zeigt das Klassendiagramm der Game Environment für verschiedene Pokervarianten. Im Diagramm ist zu erkennen, dass die Game Environments voneinander erben, wodurch einige Bestandteile wiederverwendet werden können.

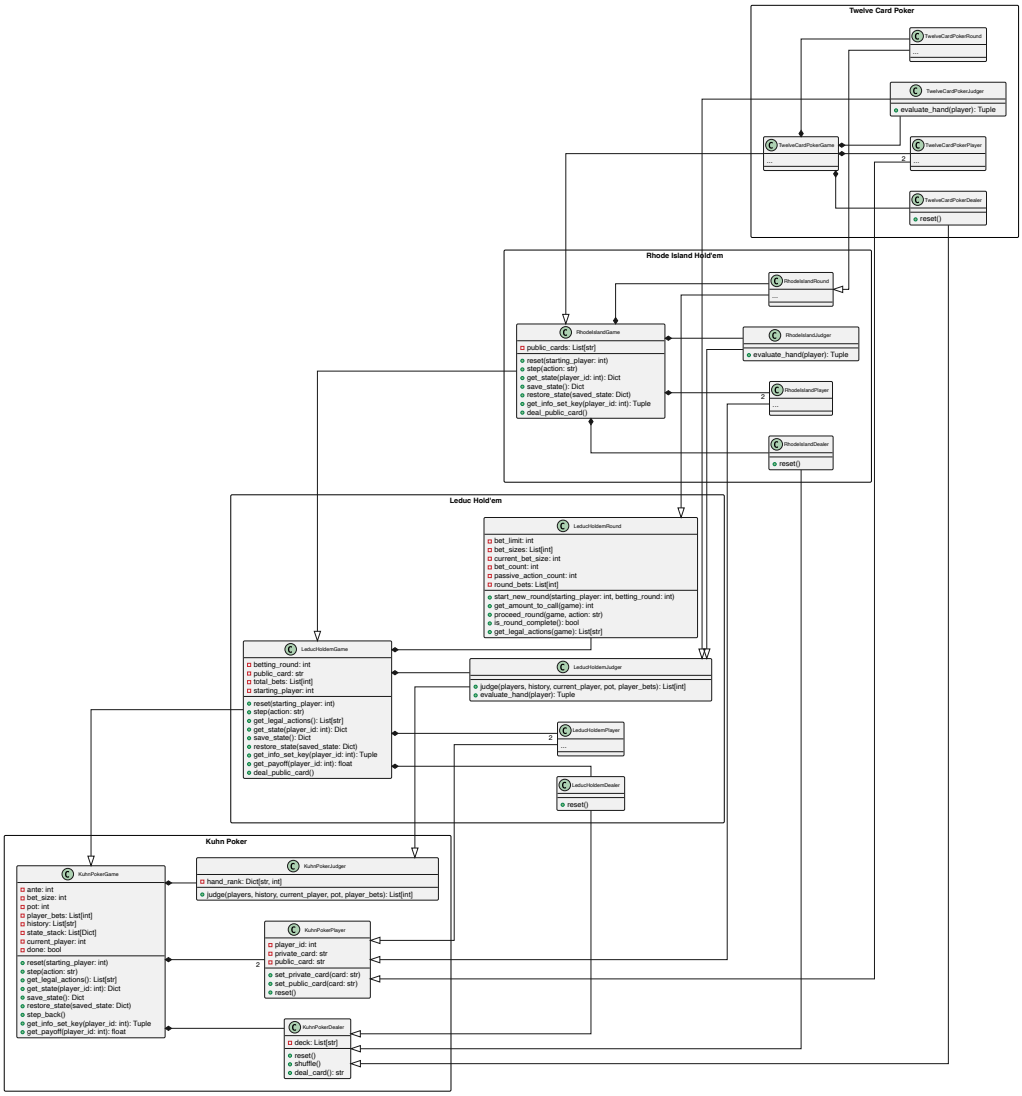

Abbildung 4.1: Klassendiagramm der Game Environment für verschiedene Pokervarianten

4.2 CFR Solver

Abbildung 4.2 zeigt das Klassendiagramm der CFR Solver Architektur.

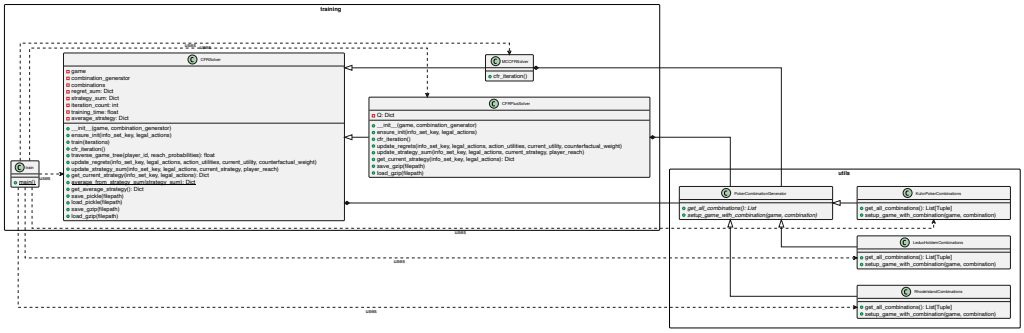

Abbildung 4.2: Klassendiagramm der CFR Solver Architektur

Das Diagramm zeigt die drei implementierten Solver Varianten CFRSolver, CFRPlusSolver und MCCFRSolver, wobei CFRPlusSolver und MCCFRSolver von CFRSolver erben.

4.2.1 CFR Training Ablauf

Abbildung 4.3 zeigt den Ablauf des CFR Trainings als Aktivitätsdiagramm.

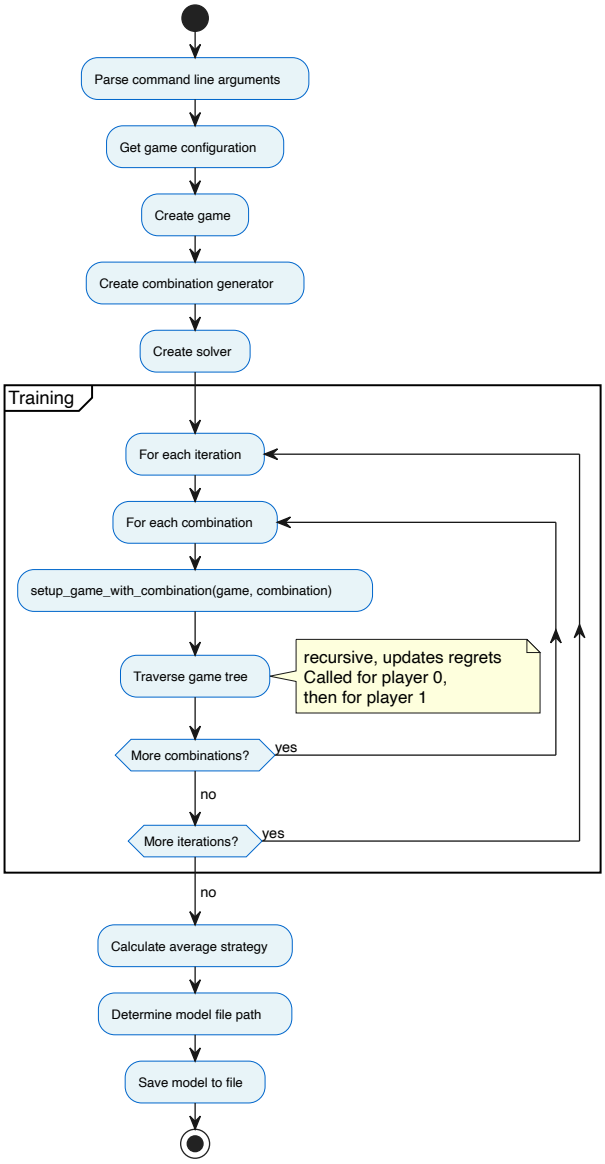

Abbildung 4.3: Aktivitätsdiagramm des CFR Trainings

Der Prozess beginnt mit dem Einlesen der Kommandozeilenargumente. Anschließend wird die Spielkonfiguration geladen. Danach werden das Spiel, der Combination Generator und der Solver erstellt. Der Combination Generator erzeugt alle möglichen Kartenkombinationen. Das Training besteht aus zwei verschachtelten Schleifen: einer äußeren Schleife über die Iterationen und einer inneren Schleife über alle Kombinationen. Für jede Kombination wird das Spiel initialisiert, der Spielbaum durchlaufen und die Regrets aktualisiert. Nach Abschluss aller Iterationen wird die durchschnittliche Strategie berechnet und das trainierte Modell gespeichert.

4.2.2 Traverse Game Tree

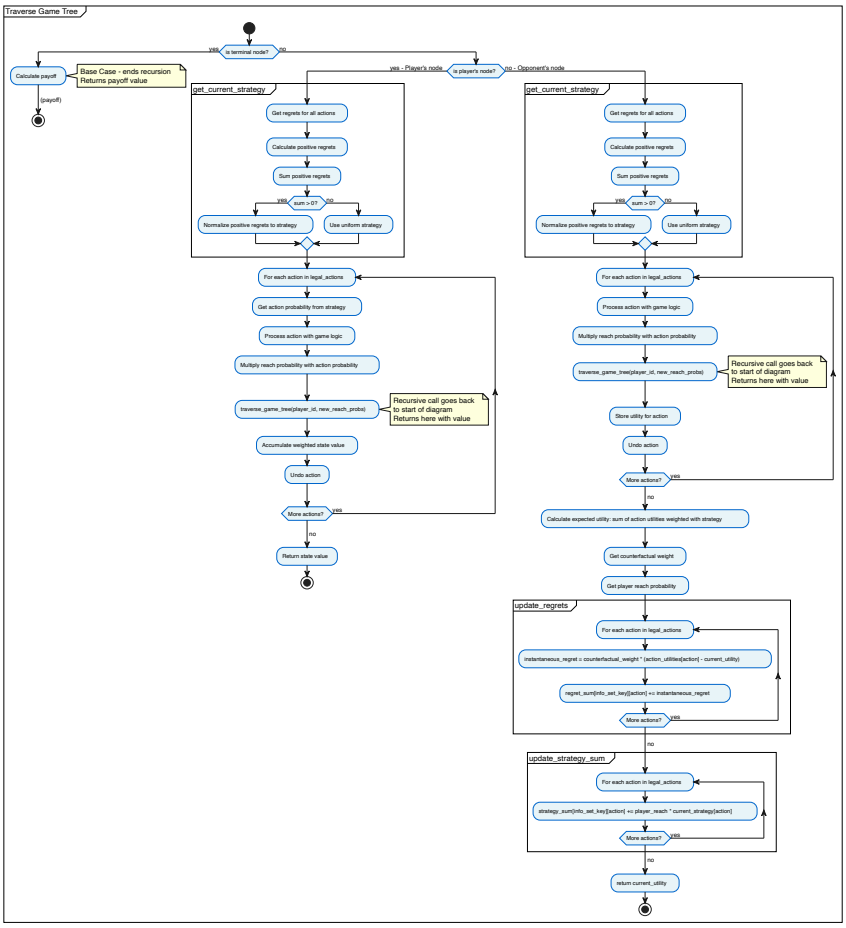

Abbildung 4.4: Aktivitätsdiagramm der Traversierung des Spielbaums

Abbildung 4.4 zeigt den Ablauf der rekursiven Traversierung des Spielbaums. Der Algorithmus beginnt mit einer Prüfung, ob es sich um einen Terminalknoten handelt. Falls ja, wird der Payoff berechnet und zurückgegeben. Handelt es sich um einen Spielerknoten, wird die aktuelle Strategie mittels Regret Matching bestimmt. Für jede legale Aktion wird die Aktion ausgeführt, die Reach Wahrscheinlichkeiten aktualisiert und rekursiv der Spielbaum durchlaufen. Nach dem rekursiven Aufruf wird der gewichtete Zustandswert akkumuliert und die Aktion rückgängig gemacht. Handelt es sich um einen Gegnerknoten, wird die Gegnerstrategie verwendet, um die Aktionswahrscheinlichkeiten zu bestimmen und den Spielbaum entsprechend zu traversieren.

4.2.3 Strategy Agent und Logger

Nach dem Training des CFR Solvers wird die errechnete durchschnittliche Strategie von einem Strategy Agent ausgeführt. Der Strategy Agent bestimmt das entsprechende Informationsset für den aktuellen Spielzustand und ermittelt die zugehörigen Aktionswahrscheinlichkeiten aus der Strategie. Anschließend wählt er basierend auf dieser Wahrscheinlichkeitsverteilung zufällig eine Aktion aus und führt sie aus.

Kapitel 5

Implementierung

5.1 Game Environment

Grundstruktur Player, Judger, Dealer, Game, Round

5.2 CFR Solver

Initialisierung, Combination Generator

Training Loop

Regret Matching

Average Strategy

Storage

5.3 Evaluationsmethoden

Best Response Agent

Exploitability Berechnung

Selfplay

Kapitel 6

Evaluation

6.1 Ergebnisse

Kuhn Poker Ergebnisse

Leduc Hold'em Ergebnisse

Eigene Version

Rhode Island Hold'em Ergebnisse

6.2 Vergleich der Algorithmen

CFR vs. CFR+

CFR vs. MCCFR

Konvergenzplots

Abstraktionsmethoden, Multithread

6.3 Vergleich mit Literaturwerten und anderen Modellen

Kuhn 1951 (analytische Lösung)

Zinkevich 2007 (CFR)

Lanctot et al. 2009 (MCCFR)

Tammelin et al. 2015 (CFR+)

OpenSpiel/RL Card

Random Leute in Foren

Kapitel 7

Fazit

7.1 Zusammenfassung

Ergebnisse

Erkenntnisse

7.2 Lessons Learned

Herausforderungen

Lösungsansätze

7.3 Future Work

Literaturverzeichnis

[Bowling et al., 2015] Bowling, M., Burch, N., Johanson, M., and Tammelin, O. (2015). Heads-up limit hold'em poker is solved. *Science*, 347(6218):145–149.

[Brown and Sandholm, 2017] Brown, N. and Sandholm, T. (2017). Superhuman ai for heads-up no-limit poker: Libratus beats top professionals. *Science*, 356(6337):508–513.

[Brown and Sandholm, 2019] Brown, N. and Sandholm, T. (2019). Superhuman ai for multiplayer poker. *Science*, 365(6456):885–890.

[Herbster and Warmuth, 1998] Herbster, M. and Warmuth, M. K. (1998). Tracking the best expert. *Machine Learning*, 32(2):151–178.

[Kuhn, 1951] Kuhn, H. W. (1951). Simplified two-person poker. *Contributions to the Theory of Games*, 1:97–103.

[Lanctot et al., 2009] Lanctot, M., Waugh, K., Zinkevich, M., and Bowling, M. (2009). Monte carlo sampling for regret minimization in extensive games. In *Advances in Neural Information Processing Systems*, pages 1078–1086.

[Osborne and Rubinstein, 1994] Osborne, M. J. and Rubinstein, A. (1994). *A Course in Game Theory*. MIT Press, Cambridge, Massachusetts.

[Shi and Littman, 2001] Shi, J. and Littman, M. L. (2001). Rhode island hold'em poker. In *AAAI/IAAI*, pages 602–607.

[Southey et al., 2005] Southey, F., Bowling, M., Larson, B., Piccione, C., Burch, N., Billings, D., and Rayner, C. (2005). Bayes' bluff: Opponent modelling in poker. In *Proceedings of the 21st Conference on Uncertainty in Artificial Intelligence (UAI 2005)*.

[Tammelin et al., 2015] Tammelin, O., Burch, N., Johanson, M., and Bowling, M. (2015). Solving heads-up limit texas hold'em. In *Proceedings of the Twenty-Fourth International Joint Conference on Artificial Intelligence (IJCAI 2015)*, pages 645–652.

[Zinkevich et al., 2007] Zinkevich, M., Johanson, M., Bowling, M., and Piccione, C. (2007). Regret minimization in games with incomplete information. In *Advances in Neural Information Processing Systems*.